

Fase 5 - Selección clásica de características

Este notebook reconstruye la lectura científica de la Fase 5 a partir de los artefactos ya ejecutados. No reajusta selectores ni recalcula métricas: interpreta rankings, estabilidad, permutaciones, redundancia, evidencias heredadas y datasets reducidos guardados previamente.

La regla metodológica se mantiene intacta: cada selector se ajustó con `X\_train, y\_train`; validation y test solo reciben las columnas ya seleccionadas. Las tablas completas permanecen en `results/tables/05\_feature\_selection/` y aquí se muestran vistas compactas diseñadas para lectura humana.

```
In [1]: from pathlib import Path
import base64
import html
import os
import sys

import numpy as np
import pandas as pd
from pandas.errors import EmptyDataError
from IPython.display import HTML, Markdown, display

cwd = Path.cwd().resolve()
PROJECT_ROOT = cwd if (cwd / "src").exists() else cwd.parent
os.chdir(PROJECT_ROOT)
if str(PROJECT_ROOT / "src") not in sys.path:
    sys.path.insert(0, str(PROJECT_ROOT / "src"))

TABLE_DIR = PROJECT_ROOT / "results/tables/05_feature_selection"
FIGURE_DIR = PROJECT_ROOT / "results/figures/05_feature_selection"
REPORT_DIR = PROJECT_ROOT / "results/reports/05_feature_selection"
SELECTED_DIR = PROJECT_ROOT / "data/selected_features"

pd.set_option("display.max_columns", 12)
pd.set_option("display.width", 140)

TABLAS_REQUERIDAS = [
    "fs_input_dataset_summary.csv",
    "fs_inherited_warnings.csv",
    "fs_train_input_quality.csv",
    "fs_column_alignment_check.csv",
    "fs_method_registry.csv",
    "fs_method_configurations.csv",
    "fs_k_values_by_dataset.csv",
    "fs_sampling_plan.csv",
    "fs_sampling_representativeness.csv",
```

```

"fs_baseline_summary.csv",
"fs_all_rankings.csv",
"fs_all_selected_features.csv",
"fs_all_execution_times.csv",
"fs_method_profiles.csv",
"fs_jaccard_stability.csv",
"fs_kuncheva_stability.csv",
"fs_permutation_summary.csv",
"fs_redundancy_vs_full.csv",
"fs_selected_feature_evidence_map.csv",
"fs_suspicious_selected_features.csv",
"fs_figures_selected_for_report.csv",
"fs_visual_audit.csv",
"fs_reduced_datasets_log.csv",
"fs_column_consistency_check.csv",
"fs_phase6_input_recommendations.csv",
"fs_phase5_final_checklist.csv",
"fs_phase5_handoff_to_phase6.csv",
"fs_phase5_open_issues.csv",
]

def cargar_csv(nombre):
    ruta = TABLE_DIR / nombre
    if not ruta.exists():
        raise FileNotFoundError(f"No existe {ruta}")
    try:
        return pd.read_csv(ruta)
    except EmptyDataError:
        return pd.DataFrame()

def _ruta_relativa_si_procede(valor):
    texto = str(valor)
    try:
        ruta = Path(texto)
        if ruta.is_absolute():
            return str(ruta.relative_to(PROJECT_ROOT))
    except Exception:
        pass
    return texto

def _truncar_texto(valor, max_caracteres=82):
    if pd.isna(valor):
        return ""
    texto = _ruta_relativa_si_procede(valor)
    texto = " ".join(str(texto).split())
    return texto if len(texto) <= max_caracteres else texto[: max_caracteres]

def mostrar_tabla_compacta(tabla, titulo, columnas=None, ordenar_por=None, a
    vista = tabla.copy()
    if columnas is not None:
        vista = vista[[col for col in columnas if col in vista.columns]]
    elif len(vista.columns) > max_columnas:

```

```

        vista = vista[list(vista.columns[:max_columnas])]
    if ordenar_por is not None and ordenar_por in vista.columns:
        vista = vista.sort_values(ordenar_por, ascending=ascendente)
    if len(vista) > max_filas:
        vista = vista.iloc[:max_filas].copy()
    if formato:
        for columna, funcion in formato.items():
            if columna in vista.columns:
                vista[columna] = vista[columna].map(funcion)
    for columna in vista.select_dtypes(include="object").columns:
        vista[columna] = vista[columna].map(_truncar_texto)
    display(Markdown(f"***{titulo}** \n{len(tabla)} filas completas en CSV;"))
    display(vista)
    return vista

def mostrar_figura(ruta_relativa, titulo=None):
    ruta = PROJECT_ROOT / ruta_relativa
    if not ruta.exists():
        display(Markdown(f"***Figura no encontrada:** `{ruta_relativa}`"))
        return
    if titulo:
        display(Markdown(f"***{titulo}***"))
    mime = "image/svg+xml" if ruta.suffix.lower() == ".svg" else "image/png"
    data = base64.b64encode(ruta.read_bytes()).decode("ascii")
    alt = html.escape(titulo or ruta.name)
    display(HTML(f"<img src='data:{mime};base64,{data}' alt='{alt}' style='width: 100%; height: auto;'/>"))

def porcentaje(valor):
    if pd.isna(valor):
        return ""
    return f"{100 * valor:.1f}%" if abs(valor) <= 1 else f"{valor:.1f}%"

def numero(valor):
    if pd.isna(valor):
        return ""
    return f"{valor:.3f}"

artefactos = {nombre: cargar_csv(nombre) for nombre in TABLAS_REQUERIDAS}
resumen_artefactos = pd.DataFrame(
    [
        {
            "artefacto": nombre,
            "filas": len(tabla),
            "columnas": len(tabla.columns),
            "ruta": str((TABLE_DIR / nombre).relative_to(PROJECT_ROOT)),
        }
        for nombre, tabla in artefactos.items()
    ]
)

```

Inventario de artefactos usados

****Pregunta.**** ¿La reconstrucción narrativa parte de artefactos existentes y trazables?

****Criterio.**** El notebook lee CSV y figuras ya generados por la fase. Si falta un artefacto requerido, la ejecución se detiene; si existe, se usa como evidencia, no como plantilla decorativa.

```
In [2]: mostrar_tabla_compacta(  
        resumen_artefactos,  
        "Artefactos tabulares cargados para la reconstrucción narrativa",  
        columnas=["artefacto", "filas", "columnas", "ruta"],  
        max_filas=10,  
    )
```

Artefactos tabulares cargados para la reconstrucción narrativa

28 filas completas en CSV; se muestra una vista compacta de 10 filas.

	artefacto	filas	columnas	
0	fs_input_dataset_summary.csv	5	7	results/tables/05_feature_selection/fs_
1	fs_inherited_warnings.csv	26	7	results/tables/05_feature_selection/f
2	fs_train_input_quality.csv	5	5	results/tables/05_feature_selection/1
3	fs_column_alignment_check.csv	5	5	results/tables/05_feature_selection/fs_
4	fs_method_registry.csv	7	10	results/tables/05_feature_selection/fs_i
5	fs_method_configurations.csv	35	5	results/tables/05_feature_selection/fs_i
6	fs_k_values_by_dataset.csv	24	5	results/tables/05_feature_selection/fs
7	fs_sampling_plan.csv	5	6	results/tables/05_feature_selection/fs_
8	fs_sampling_representativeness.csv	5	3	results/tables/05_feature_selection/fs_
9	fs_baseline_summary.csv	15	4	results/tables/05_feature_selection/fs

Out[2]:

	artefacto	filas	columnas	
0	fs_input_dataset_summary.csv	5	7	results/tables/05_feature_selection/
1	fs_inherited_warnings.csv	26	7	results/tables/05_feature_selection
2	fs_train_input_quality.csv	5	5	results/tables/05_feature_selection
3	fs_column_alignment_check.csv	5	5	results/tables/05_feature_selection/f
4	fs_method_registry.csv	7	10	results/tables/05_feature_selection/fs
5	fs_method_configurations.csv	35	5	results/tables/05_feature_selection/fs
6	fs_k_values_by_dataset.csv	24	5	results/tables/05_feature_selection/
7	fs_sampling_plan.csv	5	6	results/tables/05_feature_selection/
8	fs_sampling_representativeness.csv	5	3	results/tables/05_feature_selection/
9	fs_baseline_summary.csv	15	4	results/tables/05_feature_selection.

```
In [3]: dataset_summary = artefactos["fs_input_dataset_summary.csv"]
method_registry = artefactos["fs_method_registry.csv"]
method_profiles = artefactos["fs_method_profiles.csv"]
execution_times = artefactos["fs_all_execution_times.csv"]
all_rankings = artefactos["fs_all_rankings.csv"]
jaccard = artefactos["fs_jaccard_stability.csv"]
kuncheva = artefactos["fs_kuncheva_stability.csv"]
permutation = artefactos["fs_permutation_summary.csv"]
redundancy = artefactos["fs_redundancy_vs_full.csv"]
evidence_map = artefactos["fs_selected_feature_evidence_map.csv"]
phase6_recommendations = artefactos["fs_phase6_input_recommendations.csv"]
figures = artefactos["fs_figures_selected_for_report.csv"]
visual_audit = artefactos["fs_visual_audit.csv"]

stability_summary = (
    jaccard.groupby(["dataset", "method"], as_index=False)
    .agg(mean_jaccard=("jaccard", "mean"), min_jaccard=("jaccard", "min"))
)
redundancy_summary = (
    redundancy.groupby(["dataset", "method"], as_index=False)
    .agg(mean_selected_corr=("selected_mean_abs_corr", "mean"), max_selected
)
method_dataset_profile = (
    execution_times.groupby(["dataset", "method"], as_index=False)
    .agg(mean_elapsed_seconds=("elapsed_seconds", "mean"), sample_applied=(
    .merge(stability_summary, on=["dataset", "method"], how="left")
    .merge(redundancy_summary, on=["dataset", "method"], how="left")
)

principal_phase6 = phase6_recommendations[phase6_recommendations["rol_fase6"]
principal_profile = principal_phase6.merge(
    method_dataset_profile,
    on=["dataset", "method"],
    how="left",
```

```

)

selection_frequency = (
    all_rankings[(all_rankings["selected"]) & (all_rankings["seed"].eq(42))
    .groupby(["dataset", "feature"], as_index=False)
    .agg(n_methods=("method", "nunique"), best_rank=("rank", "min"))
    .sort_values(["dataset", "n_methods", "best_rank"], ascending=[True, Fal
)

top_features_by_dataset = (
    selection_frequency.groupby("dataset").cumcount() <
    .reset_index(drop=True)
)

dataset_method_reading = principal_profile.copy()
mean_jaccard_numeric = pd.to_numeric(dataset_method_reading["mean_jaccard"],
mean_selected_corr_numeric = pd.to_numeric(dataset_method_reading["mean_sele
dataset_method_reading["lectura"] = np.where(
    mean_jaccard_numeric >= 0.85,
    "estable entre semillas",
    "sensible a semilla o alternativas equivalentes",
)
dataset_method_reading["cautela_redundancia"] = np.where(
    mean_selected_corr_numeric >= 0.5,
    "vigilar redundancia",
    "redundancia contenida",
)
)

```

5.1 Splits y advertencias heredadas

****Pregunta.**** ¿Qué problemas y cautelas entran a la selección clásica desde las fases anteriores?

****Artefactos usados.****
`fs\_input\_dataset\_summary.csv`, `fs\_inherited\_warnings.csv`,
handoff de Fase 4 y splits de `data/splits/`.

****Criterio metodológico.**** Fase 5 solo continúa con datasets aceptados en Fase 4. `olive\_oil` se trata como dos problemas distintos (`olive\_oil\_3class` y `olive\_oil\_9class`) y no como un dataset ambiguo.

```

In [4]: mostrar_tabla_compacta(
    dataset_summary,
    "Tamaño y dimensionalidad de los datasets que entran a selección",
    columnas=["dataset", "train_rows", "validation_rows", "test_rows", "raw_
    max_filas=8,
)

inherited = artefactos["fs_inherited_warnings.csv"]
if len(inherited):
    columnas_warning = [col for col in ["dataset", "tipo", "gravedad", "ries
    mostrar_tabla_compacta(inherited, "Cautelas heredadas relevantes", colum

```

```
else:
    display(Markdown("No hay advertencias heredadas registradas en `fs_inher
```

Tamaño y dimensionalidad de los datasets que entran a selección

5 filas completas en CSV; se muestra una vista compacta de 5 filas.

	dataset	train_rows	validation_rows	test_rows	raw_features	processo
0	breast_cancer_wisconsin	397	86	86	30	
1	customer_churn	308582	66125	66125	10	
2	madelon	1400	300	300	500	
3	olive_oil_3class	400	86	86	8	
4	olive_oil_9class	400	86	86	8	

Cautelas heredadas relevantes

26 filas completas en CSV; se muestra una vista compacta de 12 filas.

	dataset		tipo	gravedad	riesgo	accion
0	madelon	heredado_fase3		medio	ratio features/muestras elevado	split estratificado y control de dimensionalidad
1	breast_cancer_wisconsin	heredado_fase3		bajo	redundancia alta	vigilar selección redundante
2	madelon	heredado_fase3		bajo	redundancia alta	vigilar selección redundante
3	customer_churn	heredado_fase3		medio	3 features categóricas pendientes de codificación	codificar dentro del pipeline ajustado solo co...
4	olive_oil_3class	heredado_fase3		medio	target multiclase	estratificar por clase y revisar clases minori...
5	olive_oil_3class	heredado_fase3		medio	desbalance de target	usar split estratificado
6	olive_oil_9class	heredado_fase3		medio	target multiclase	estratificar por clase y revisar clases minori...
7	olive_oil_9class	heredado_fase3		medio	desbalance de target	usar split estratificado
8	breast_cancer_wisconsin		drift	medio	8 variables con drift marginal	vigilar en selección y modelado; no usar el ra...
9	olive_oil_3class		drift	medio	1 variables con drift marginal	vigilar en selección y modelado; no usar el ra...
10	olive_oil_9class		drift	medio	1 variables con drift marginal	vigilar en selección y modelado; no usar el ra...
11	madelon	heredado_fase3		medio	ratio features/muestras elevado	split estratificado y control de dimensionalidad

Lectura. `customer_churn` exige atención por codificación ajustada solo con train; `madelon` llega con alta dimensionalidad; `breast_cancer_wisconsin` y las dos

formulaciones de Olive Oil arrastran cautelas de drift o redundancia. Estas advertencias no bloquean la fase, pero condicionan cómo interpretar estabilidad, redundancia y utilidad para Fase 6.

5.2 Protocolo y familias de métodos

****Pregunta.**** ¿Qué pregunta responde cada familia de selección y qué limitación introduce?

****Criterio metodológico.**** Se comparan filtros, filtros supervisados, relevancia-redundancia, regularización y métodos embedded. Ninguno usa validation/test para decidir columnas.

```
In [5]: familias = method_registry.copy()
familias["lectura_metodológica"] = familias["family"].map(
    {
        "filtros": "ordena variables por una propiedad simple; es barato, pe
        "filtros supervisados": "mide asociación marginal con el target; pue
        "relevancia-redundancia": "busca señal evitando variables repetidas;
        "regularizacion": "favorece subconjuntos parsimoniosos mediante pena
        "embedded": "usa un modelo para estimar importancia; puede ser estab
    }
)
mostrar_tabla_compacta(
    familias,
    "Familias, contrato train-only y limitaciones principales",
    columnas=["method", "family", "uses_target", "has_randomness", "requires
    max_filas=10,
)
```

Familias, contrato train-only y limitaciones principales

7 filas completas en CSV; se muestra una vista compacta de 7 filas.

	method	family	uses_target	has_randomness	requires_sample_when_lar
0	variance	filtros	False	False	Fal
1	f_classif	filtros supervisados	True	False	Fal
2	mutual_info	filtros supervisados	True	True	Fal
3	mrmr_approx	relevancia- redundancia	True	True	Tr
4	l1_logistic	regularizacion	True	True	Tr
5	random_forest	embedded	True	True	Tr
6	linear_svm	embedded	True	True	Tr

Out[5]:	method	family	uses_target	has_randomness	requires_sample_when_lo
0	variance	filtros	False	False	f
1	f_classif	filtros supervisados	True	False	f
2	mutual_info	filtros supervisados	True	True	f
3	mrmr_approx	relevancia- redundancia	True	True	
4	l1_logistic	regularizacion	True	True	
5	random_forest	embedded	True	True	
6	linear_svm	embedded	True	True	

Decisión. La comparación no busca declarar un selector universalmente mejor. Busca una base clásica defendible para contrastar en Fase 6: métodos baratos para referencia, métodos supervisados para señal marginal, métodos multivariantes para redundancia y métodos embedded para importancias dependientes de modelo.

5.3 Preparación de matrices y contrato train-only

****Pregunta.**** ¿Las matrices que reciben los selectores cumplen el contrato de no fuga?

****Artefactos usados.**** `fs\_train\_input\_quality.csv`,
`fs\_column\_alignment\_check.csv`,
`fs\_suspicious\_selected\_features.csv`.

****Criterio metodológico.**** El preprocesado que afecta a variables predictoras se ajusta en train y se aplica a validation/test. Las columnas prohibidas no entran en X.

```
In [6]: quality = artefactos["fs_train_input_quality.csv"]
alignment = artefactos["fs_column_alignment_check.csv"]
suspicious = artefactos["fs_suspicious_selected_features.csv"]
```

```
mostrar_tabla_compacta(quality, "Calidad de entrada por dataset", max_filas=
mostrar_tabla_compacta(alignment, "Alineación train/validation/test y ausencia
display(Markdown(f"**Variables sospechosas seleccionadas:** {len(suspicious)"))
```

Calidad de entrada por dataset

5 filas completas en CSV; se muestra una vista compacta de 5 filas.

	dataset	n_missing_train	n_infinite_train	duplicated_feature_names	st
0	breast_cancer_wisconsin	0	0		0
1	customer_churn	0	0		0
2	madelon	0	0		0
3	olive_oil_3class	0	0		0
4	olive_oil_9class	0	0		0

Alineación train/validation/test y ausencia de target en X

5 filas completas en CSV; se muestra una vista compacta de 5 filas.

	dataset	same_columns_train_validation_test	x_y_train_aligned	target_i
0	breast_cancer_wisconsin		True	True
1	customer_churn		True	True
2	madelon		True	True
3	olive_oil_3class		True	True
4	olive_oil_9class		True	True

Variables sospechosas seleccionadas: 0 registros.

Interpretación. La evidencia apunta a matrices alineadas y sin selección de columnas sospechosas. La ausencia de sospechosas no garantiza ausencia absoluta de proxies semánticos; por eso el riesgo residual se mantiene documentado para modelado.

5.4 Configuración real de métodos

****Pregunta.**** ¿Qué métodos se ejecutan completos y cuáles requieren control de coste?

****Criterio metodológico.**** Los métodos baratos se ejecutan sobre train completo. En datasets grandes, los métodos costosos pueden usar muestra estratificada documentada; sus tiempos no se comparan como si fueran ejecución completa.

```
In [7]: config = artefactos["fs_method_configurations.csv"]
config_resumen = config.pivot_table(index="dataset", columns="decision", val
```

```

mostrar_tabla_compacta(config_resumen, "Plan de ejecución por dataset", max_
mostrar_tabla_compacta(
    method_dataset_profile,
    "Coste, muestreo y estabilidad por dataset-método",
    columnas=["dataset", "method", "mean_elapsed_seconds", "sample_applied",
    ordenar_por="mean_elapsed_seconds",
    ascendente=False,
    max_filas=12,
    formato={"mean_elapsed_seconds": numero, "mean_jaccard": numero, "mean_s
)

```

Plan de ejecución por dataset

5 filas completas en CSV; se muestra una vista compacta de 5 filas.

decision	dataset	execute_full_train	execute_with_stratified_sample
0	breast_cancer_wisconsin	7	0
1	customer_churn	2	5
2	madelon	7	0
3	olive_oil_3class	7	0
4	olive_oil_9class	7	0

Coste, muestreo y estabilidad por dataset-método

35 filas completas en CSV; se muestra una vista compacta de 12 filas.

	dataset	method	mean_elapsed_seconds	sample_applied	mean_s
17	madelon	mrmr_approx	1.805	False	
15	madelon	l1_logistic	1.284	False	
18	madelon	mutual_info	0.988	False	
12	customer_churn	random_forest	0.817	True	
5	breast_cancer_wisconsin	random_forest	0.666	False	
33	olive_oil_9class	random_forest	0.626	False	
26	olive_oil_3class	random_forest	0.617	False	
19	madelon	random_forest	0.284	False	
1	breast_cancer_wisconsin	l1_logistic	0.112	False	
10	customer_churn	mrmr_approx	0.103	True	
11	customer_churn	mutual_info	0.101	True	
16	madelon	linear_svm	0.038	False	

Out[7]:

	dataset	method	mean_elapsed_seconds	sample_applied	me
17	madelon	mrmmr_approx	1.805	False	
15	madelon	l1_logistic	1.284	False	
18	madelon	mutual_info	0.988	False	
12	customer_churn	random_forest	0.817	True	
5	breast_cancer_wisconsin	random_forest	0.666	False	
33	olive_oil_9class	random_forest	0.626	False	
26	olive_oil_3class	random_forest	0.617	False	
19	madelon	random_forest	0.284	False	
1	breast_cancer_wisconsin	l1_logistic	0.112	False	
10	customer_churn	mrmmr_approx	0.103	True	
11	customer_churn	mutual_info	0.101	True	
16	madelon	linear_svm	0.038	False	

Decisión. La salida de métodos fallidos se conserva como evidencia negativa. En la ejecución actual no hay métodos fallidos ni warnings de método, por lo que la comparación puede apoyarse en todos los selectores registrados.

5.5 Valores de k

****Pregunta.**** ¿Las reducciones de dimensionalidad son razonables para cada dataset?

****Criterio metodológico.**** Los valores de k se acotan por número de variables disponibles: no se exige el mismo k a Olive Oil que a Madelon. La figura se muestra aquí porque explica el diseño experimental, no al final como galería.


```
In [8]: k_values = artefactos["fs_k_values_by_dataset.csv"]
k_compacto = (
    k_values.groupby("dataset", as_index=False)
    .agg(n_features=("n_features", "max"), k_values=("k", lambda serie: ", "
))
mostrar_tabla_compacta(k_compacto, "Valores de k por dataset", max_filas=8,
mostrar_figura("results/figures/05_feature_selection/protocol/fs_k_reduction")
```

Valores de k por dataset

5 filas completas en CSV; se muestra una vista compacta de 5 filas.

	dataset	n_features	k_values	max_reduction_pct
0	breast_cancer_wisconsin	30	3, 5, 10, 15, 20, 30	90.0%
1	customer_churn	15	1, 4, 5, 10, 15	93.3%
2	madelon	500	5, 10, 15, 20, 22, 30, 50	99.0%
3	olive_oil_3class	8	3, 5, 8	62.5%
4	olive_oil_9class	8	3, 5, 8	62.5%

Plan de k y reducción dimensional



Implicación para Fase 6. Los subconjuntos con k pequeño permiten comparar modelos bajo reducción agresiva; los k cercanos a la dimensionalidad original sirven como control de sensibilidad.

5.6 Muestreo para coste computacional

****Pregunta.**** ¿El control de coste altera de forma visible la distribución del target?

****Criterio metodológico.**** El muestreo solo se usa para métodos costosos y se registra. La representatividad se evalúa con diferencia máxima de proporciones del target.

```
In [9]: sampling = artefactos["fs_sampling_plan.csv"].merge(artefactos["fs_sampling_
mostrar_tabla_compacta(
    sampling,
    "Muestreo y representatividad por dataset",
    columnas=["dataset", "sample_applied", "sample_size", "train_size", "max
max_filas=8,
    formato={"max_abs_target_prop_diff": porcentaje},
)
```

Muestreo y representatividad por dataset

5 filas completas en CSV; se muestra una vista compacta de 5 filas.

	dataset	sample_applied	sample_size	train_size	max_abs_target_prop_
0	breast_cancer_wisconsin	False	397	397	0
1	customer_churn	True	5000	308582	0
2	madelon	False	1400	1400	0
3	olive_oil_3class	False	400	400	0
4	olive_oil_9class	False	400	400	0

Out[9]:

	dataset	sample_applied	sample_size	train_size	max_abs_target_pro
0	breast_cancer_wisconsin	False	397	397	
1	customer_churn	True	5000	308582	
2	madelon	False	1400	1400	
3	olive_oil_3class	False	400	400	
4	olive_oil_9class	False	400	400	

Interpretación. `customer_churn` es el único dataset con muestra estratificada por tamaño. La diferencia máxima de proporciones registrada es muy baja, pero los

tiempos de sus métodos muestreados deben leerse como tiempos sobre muestra, no sobre train completo.

5.7 y 5.8 Selección baseline y selección clásica completa

****Pregunta.**** ¿Qué métodos producen señal recurrente y qué variables aparecen repetidamente por dataset?

****Criterio metodológico.**** La baseline rápida se interpreta como referencia mínima. La selección completa incorpora métodos con distintas hipótesis para evitar que una sola familia dicte la narrativa.

```
In [10]: baseline = artefactos["fs_baseline_summary.csv"]
mostrar_tabla_compacta(
    baseline,
    "Resumen de baseline rápida",
    columnas=["dataset", "method", "mean_elapsed_seconds", "n_selected_rows",
ordenar_por="dataset",
max_filas=15,
formato={"mean_elapsed_seconds": numero},
)
mostrar_tabla_compacta(
    top_features_by_dataset,
    "Variables más recurrentes por dataset en selección completa",
    columnas=["dataset", "feature", "n_methods", "best_rank"],
    max_filas=20,
)
```

Resumen de baseline rápida

15 filas completas en CSV; se muestra una vista compacta de 15 filas.

	dataset	method	mean_elapsed_seconds	n_selected_rows
0	breast_cancer_wisconsin	f_classif	0.000	249
1	breast_cancer_wisconsin	mutual_info	0.025	249
2	breast_cancer_wisconsin	variance	0.000	249
3	customer_churn	f_classif	0.029	105
4	customer_churn	mutual_info	0.101	105
5	customer_churn	variance	0.032	105
6	madelon	f_classif	0.002	456
7	madelon	mutual_info	0.988	456
8	madelon	variance	0.002	456
9	olive_oil_3class	f_classif	0.000	48
10	olive_oil_3class	mutual_info	0.009	48
11	olive_oil_3class	variance	0.000	48
12	olive_oil_9class	f_classif	0.001	48
13	olive_oil_9class	mutual_info	0.017	48
14	olive_oil_9class	variance	0.000	48

Variables más recurrentes por dataset en selección completa

30 filas completas en CSV; se muestra una vista compacta de 20 filas.

	dataset	feature	n_methods	best_rank
0	breast_cancer_wisconsin	area_worst	7	1
1	breast_cancer_wisconsin	compactness_worst	7	1
2	breast_cancer_wisconsin	concave_points_worst	7	1
3	breast_cancer_wisconsin	perimeter_worst	7	1
4	breast_cancer_wisconsin	radius_se	7	1
5	breast_cancer_wisconsin	radius_worst	7	1
6	customer_churn	contract_length_Monthly	7	1
7	customer_churn	support_calls	7	1
8	customer_churn	tenure	7	1
9	customer_churn	total_spend	7	2
10	customer_churn	age	7	3
11	customer_churn	contract_length_Annual	7	3
12	madelon	feat_241	6	1
13	madelon	feat_475	5	1
14	madelon	feat_44	5	2
15	madelon	feat_128	5	4
16	madelon	feat_153	5	4
17	madelon	feat_48	4	2
18	olive_oil_3class	other	7	1
19	olive_oil_3class	stearic	7	1


Out[10]:

	dataset	feature	n_methods	best_rank
0	breast_cancer_wisconsin	area_worst	7	1
1	breast_cancer_wisconsin	compactness_worst	7	1
2	breast_cancer_wisconsin	concave_points_worst	7	1
3	breast_cancer_wisconsin	perimeter_worst	7	1
4	breast_cancer_wisconsin	radius_se	7	1
5	breast_cancer_wisconsin	radius_worst	7	1
6	customer_churn	contract_length_Monthly	7	1
7	customer_churn	support_calls	7	1
8	customer_churn	tenure	7	1
9	customer_churn	total_spend	7	2
10	customer_churn	age	7	3
11	customer_churn	contract_length_Annual	7	3
12	madelon	feat_241	6	1
13	madelon	feat_475	5	1
14	madelon	feat_44	5	2
15	madelon	feat_128	5	4
16	madelon	feat_153	5	4
17	madelon	feat_48	4	2
18	olive_oil_3class	other	7	1
19	olive_oil_3class	stearic	7	1


Lectura por dataset. En Breast Cancer predominan variables morfológicas correlacionadas; en `customer_churn` aparecen variables operativas de uso, soporte y contrato; en Madelon la selección debe leerse con cautela por alta dimensionalidad y ruido; en Olive Oil las variables químicas son pocas y tienden a repetirse entre métodos, por lo que la comparación relevante se desplaza hacia estabilidad y formulación del target.

```
In [11]: for dataset in dataset_summary["dataset"]:  
          ruta = f"results/figures/05_feature_selection/top_features/{dataset}_top  
          mostrar_figura(ruta, f"Variables recurrentes en {dataset}")
```


Variables recurrentes en breast_cancer_wisconsin




Variables recurrentes en customer_churn




Variables recurrentes en madelon



Variables recurrentes en olive_oil_3class



Variables recurrentes en olive_oil_9class



5.9 Guardado tidy de rankings, subconjuntos y tiempos

****Pregunta.**** ¿Los resultados son trazables sin convertir el notebook en un inventario gigante?

****Criterio metodológico.**** El detalle completo permanece en CSV largos (`fs\_all\_rankings.csv`, `fs\_all\_selected\_features.csv`, `fs\_all\_execution\_times.csv`). El notebook solo muestra perfiles que ayudan a interpretar.

```
In [12]: trazabilidad = pd.DataFrame(
    [
        {"artefacto": "fs_all_rankings.csv", "filas": len(artefactos["fs_all_rankings.csv"])},
        {"artefacto": "fs_all_selected_features.csv", "filas": len(artefactos["fs_all_selected_features.csv"])},
        {"artefacto": "fs_all_execution_times.csv", "filas": len(artefactos["fs_all_execution_times.csv"])},
        {"artefacto": "fs_phase6_input_recommendations.csv", "filas": len(artefactos["fs_phase6_input_recommendations.csv"])},
    ]
)
mostrar_tabla_compacta(trazabilidad, "Artefactos largos preservados fuera de notebook")
```

Artefactos largos preservados fuera del notebook

4 filas completas en CSV; se muestra una vista compacta de 4 filas.

	artefacto	filas	uso
0	fs_all_rankings.csv	79863	ranking largo por dataset, método, seed, k y v...
1	fs_all_selected_features.csv	6342	subconjuntos seleccionados en formato trazable
2	fs_all_execution_times.csv	105	tiempos, muestra y estado por ejecución
3	fs_phase6_input_recommendations.csv	168	entradas principales y auxiliares para Fase 6

Out[12]:

	artefacto	filas	uso
0	fs_all_rankings.csv	79863	ranking largo por dataset, método, seed, k y v...
1	fs_all_selected_features.csv	6342	subconjuntos seleccionados en formato trazable
2	fs_all_execution_times.csv	105	tiempos, muestra y estado por ejecución
3	fs_phase6_input_recommendations.csv	168	entradas principales y auxiliares para Fase 6

Decisión. No se muestran tablas largas de rankings en el notebook porque inducen lectura mecánica y duplican CSV. La evidencia completa queda guardada y recargable.

5.10 Estabilidad por semillas

****Pregunta.**** ¿La selección depende de la semilla?

****Criterio metodológico.**** Jaccard mide solapamiento de subconjuntos; Kuncheva corrige el solapamiento esperado por azar. Baja estabilidad no descarta utilidad: puede indicar variables redundantes o soluciones alternativas.

```
In [13]: stability_dataset = (
    method_dataset_profile.groupby("dataset", as_index=False)
    .agg(mean_jaccard=("mean_jaccard", "mean"), min_jaccard=("mean_jaccard",
))
mostrar_tabla_compacta(stability_dataset, "Estabilidad media por dataset", n
mostrar_tabla_compacta(
    method_dataset_profile,
    "Métodos menos estables que conviene vigilar",
    columnas=["dataset", "method", "mean_jaccard", "mean_selected_corr"],
    ordenar_por="mean_jaccard",
    max_filas=12,
    formato={"mean_jaccard": numero, "mean_selected_corr": numero},
)
```


Estabilidad media por dataset

5 filas completas en CSV; se muestra una vista compacta de 5 filas.

	dataset	mean_jaccard	min_jaccard
0	breast_cancer_wisconsin	0.979	0.852
1	customer_churn	0.920	0.742
2	madelon	0.703	0.111
3	olive_oil_3class	1.000	1.000
4	olive_oil_9class	0.979	0.926

Métodos menos estables que conviene vigilar

35 filas completas en CSV; se muestra una vista compacta de 12 filas.

	dataset	method	mean_jaccard	mean_selected_corr
17	madelon	mrmr_approx	0.111	0.017
18	madelon	mutual_info	0.127	0.053
19	madelon	random_forest	0.681	0.306
11	customer_churn	mutual_info	0.742	0.096
10	customer_churn	mrmr_approx	0.756	0.075
5	breast_cancer_wisconsin	random_forest	0.852	0.681
33	olive_oil_9class	random_forest	0.926	0.461
31	olive_oil_9class	mrmr_approx	0.926	0.332
8	customer_churn	l1_logistic	0.964	0.088
9	customer_churn	linear_svm	0.976	0.142
28	olive_oil_9class	f_classif	1.000	0.461
27	olive_oil_3class	variance	1.000	0.552

Out[13]:

	dataset	method	mean_jaccard	mean_selected_corr
17	madelon	mrmmr_approx	0.111	0.017
18	madelon	mutual_info	0.127	0.053
19	madelon	random_forest	0.681	0.306
11	customer_churn	mutual_info	0.742	0.096
10	customer_churn	mrmmr_approx	0.756	0.075
5	breast_cancer_wisconsin	random_forest	0.852	0.681
33	olive_oil_9class	random_forest	0.926	0.461
31	olive_oil_9class	mrmmr_approx	0.926	0.332
8	customer_churn	l1_logistic	0.964	0.088
9	customer_churn	linear_svm	0.976	0.142
28	olive_oil_9class	f_classif	1.000	0.461
27	olive_oil_3class	variance	1.000	0.552

Implicación para Fase 6. Los métodos estables son candidatos naturales para la parrilla inicial. Los métodos menos estables pueden mantenerse como sensibilidad si el rendimiento de validación compensa esa incertidumbre.

5.11 Permutaciones del target

****Pregunta.**** ¿Los scores reales superan una referencia nula simple?

****Criterio metodológico.**** Se compara el score real con una distribución nula generada permutando `y\_train`. Con 20 permutaciones, la evidencia es aproximada y sirve como diagnóstico, no como prueba definitiva.


```
In [14]: mostrar_tabla_compacta(
    permutacion,
    "Resumen de variables por encima del p95 nulo",
    columnas=["dataset", "method", "n_features_above_null", "median_empirical_p_value"],
    max_filas=12,
    formato={"median_empirical_p_value": numero},
)
mostrar_figura("results/figures/05_feature_selection/permutation/fs_permutat")
```

Resumen de variables por encima del p95 nulo

10 filas completas en CSV; se muestra una vista compacta de 10 filas.

	dataset	method	n_features_above_null	median_empirical_p_value
0	breast_cancer_wisconsin	f_classif	26	0.048
1	breast_cancer_wisconsin	mutual_info	27	0.048
2	customer_churn	f_classif	15	0.048
3	customer_churn	mutual_info	9	0.048
4	madelon	f_classif	66	0.429
5	madelon	mutual_info	48	0.810
6	olive_oil_3class	f_classif	7	0.048
7	olive_oil_3class	mutual_info	8	0.048
8	olive_oil_9class	f_classif	8	0.048
9	olive_oil_9class	mutual_info	8	0.048

Permutaciones: score real frente a nulo



Interpretación. Breast Cancer, Churn y Olive Oil muestran más variables por encima del nulo que Madelon en varios métodos. En Madelon la señal existe, pero se reparte en un espacio de 500 variables y debe validarse con modelos posteriores.

5.12 Redundancia interna de subconjuntos

****Pregunta.**** ¿La selección reduce información repetida o conserva bloques redundantes?

****Criterio metodológico.**** Se compara correlación media/máxima de subconjuntos contra el conjunto completo. La redundancia no es siempre mala, pero puede inflar interpretaciones de importancia.

```
In [15]: redundancy_principal = principal_phase6.merge(
    redundancy,
    on=["dataset", "method", "k"],
    how="left",
)
mostrar_tabla_compacta(
    redundancy_principal,
    "Redundancia en subconjuntos principales para Fase 6",
    columnas=["dataset", "method", "k", "selected_mean_abs_corr", "selected_
ordenar_por="selected_mean_abs_corr",
    ascendente=False,
    max_filas=20,
    formato={"selected_mean_abs_corr": numero, "selected_max_abs_corr": nume
)
```

Redundancia en subconjuntos principales para Fase 6

20 filas completas en CSV; se muestra una vista compacta de 20 filas.

	dataset	method	k	selected_mean_abs_corr	selected_max_abs
3	breast_cancer_wisconsin	random_forest	10	0.819	
2	breast_cancer_wisconsin	mutual_info	10	0.819	
0	breast_cancer_wisconsin	f_classif	10	0.817	
11	madelon	random_forest	10	0.435	
1	breast_cancer_wisconsin	mrmr_approx	10	0.424	
8	madelon	f_classif	10	0.385	
16	olive_oil_9class	f_classif	8	0.330	
18	olive_oil_9class	mutual_info	8	0.330	
17	olive_oil_9class	mrmr_approx	8	0.330	
19	olive_oil_9class	random_forest	8	0.330	
13	olive_oil_3class	mrmr_approx	8	0.319	
14	olive_oil_3class	mutual_info	8	0.319	
12	olive_oil_3class	f_classif	8	0.319	
15	olive_oil_3class	random_forest	8	0.319	
7	customer_churn	random_forest	10	0.122	
6	customer_churn	mutual_info	10	0.122	
4	customer_churn	f_classif	10	0.122	
10	madelon	mutual_info	10	0.072	
5	customer_churn	mrmr_approx	10	0.050	
9	madelon	mrmr_approx	10	0.016	

Out[15]:

	dataset	method	k	selected_mean_abs_corr	selected_max_a
3	breast_cancer_wisconsin	random_forest	10	0.819	
2	breast_cancer_wisconsin	mutual_info	10	0.819	
0	breast_cancer_wisconsin	f_classif	10	0.817	
11	madelon	random_forest	10	0.435	
1	breast_cancer_wisconsin	mrmmr_approx	10	0.424	
8	madelon	f_classif	10	0.385	
16	olive_oil_9class	f_classif	8	0.330	
18	olive_oil_9class	mutual_info	8	0.330	
17	olive_oil_9class	mrmmr_approx	8	0.330	
19	olive_oil_9class	random_forest	8	0.330	
13	olive_oil_3class	mrmmr_approx	8	0.319	
14	olive_oil_3class	mutual_info	8	0.319	
12	olive_oil_3class	f_classif	8	0.319	
15	olive_oil_3class	random_forest	8	0.319	
7	customer_churn	random_forest	10	0.122	
6	customer_churn	mutual_info	10	0.122	
4	customer_churn	f_classif	10	0.122	
10	madelon	mutual_info	10	0.072	
5	customer_churn	mrmmr_approx	10	0.050	
9	madelon	mrmmr_approx	10	0.016	

Riesgo residual. Si un subconjunto tiene alta correlación interna, Fase 6 debe valorar si el rendimiento justifica esa redundancia o si conviene preferir métodos de relevancia-redundancia.

5.13 Cruce con EDA y señales sospechosas

****Pregunta.**** ¿La selección contradice o complementa la evidencia estadística previa?

****Criterio metodológico.**** Una variable sin señal univariante previa puede ser útil multivariadamente; por tanto, el cruce con EDA informa riesgos, no borra variables automáticamente.

```
In [16]: evidence = evidence_map.copy()
coverage_dataset = evidence.groupby("dataset", as_index=False).agg(mean_evidence_coverage)
mostrar_tabla_compacta(coverage_dataset, "Cobertura media de evidencia previa")
display(Markdown(f"Variables sospechosas seleccionadas: {len(artefactos)}"))
```

Cobertura media de evidencia previa por dataset

5 filas completas en CSV; se muestra una vista compacta de 5 filas.

	dataset	mean_evidence_coverage	max_evidence_coverage
0	breast_cancer_wisconsin	0.0%	0.0%
1	customer_churn	83.4%	4.0%
2	madelon	0.0%	0.0%
3	olive_oil_3class	1.6%	1.8%
4	olive_oil_9class	1.4%	1.7%

Variables sospechosas seleccionadas: 0.

Interpretación. El cruce con EDA no encuentra variables sospechosas seleccionadas. La baja cobertura de evidencia previa en algunos subconjuntos se interpreta con cautela: puede reflejar señal multivariante o limitaciones del mapeo entre nombres transformados y evidencia de fases tempranas.

5.14 Datasets reducidos para Fase 6

Pregunta. ¿Qué debe consumir Fase 6 y qué queda como material auxiliar?

Criterio metodológico. Los directorios `principal\_para\_modelado` forman una parrilla inicial compacta. El resto de subconjuntos se conserva para sensibilidad, ablación o apéndice; no se reajustan selectores en Fase 6.

```
In [17]: mostrar_tabla_compacta(
principal_profile,
"Subconjuntos principales recomendados para Fase 6",
columnas=["dataset", "method", "k", "path", "mean_jaccard", "mean_selected_corr"],
max_filas=25,
formato={"mean_jaccard": numero, "mean_selected_corr": numero},
)
consistency = artefactos["fs_column_consistency_check.csv"]
consistency_summary = consistency.groupby("dataset", as_index=False).agg(all_consistency)
mostrar_tabla_compacta(consistency_summary, "Consistencia de columnas en datasets")
```

Subconjuntos principales recomendados para Fase 6

20 filas completas en CSV; se muestra una vista compacta de 20 filas.

	dataset	method	k	
0	breast_cancer_wisconsin	f_classif	10	data/selected_features/breast_cancer_wisc
1	breast_cancer_wisconsin	mrmr_approx	10	data/selected_features/breast_cancer_wisc
2	breast_cancer_wisconsin	mutual_info	10	data/selected_features/breast_cancer_wisc
3	breast_cancer_wisconsin	random_forest	10	data/selected_features/breast_cancer_wisc
4	customer_churn	f_classif	10	data/selected_features/customer_churn/f_
5	customer_churn	mrmr_approx	10	data/selected_features/customer_churn/mrmr
6	customer_churn	mutual_info	10	data/selected_features/customer_churn/mu
7	customer_churn	random_forest	10	data/selected_features/customer_churn/rand
8	madelon	f_classif	10	data/selected_features/madelon/f_classi
9	madelon	mrmr_approx	10	data/selected_features/madelon/mrmr_appro
10	madelon	mutual_info	10	data/selected_features/madelon/mutual_inf

	dataset	method	k	
11	madelon	random_forest	10	data/selected_features/madelon/random_for
12	olive_oil_3class	f_classif	8	data/selected_features/olive_oil_3class/t
13	olive_oil_3class	mrmr_approx	8	data/selected_features/olive_oil_3class/mr
14	olive_oil_3class	mutual_info	8	data/selected_features/olive_oil_3class/m
15	olive_oil_3class	random_forest	8	data/selected_features/olive_oil_3class/rar
16	olive_oil_9class	f_classif	8	data/selected_features/olive_oil_9class/t
17	olive_oil_9class	mrmr_approx	8	data/selected_features/olive_oil_9class/mr
18	olive_oil_9class	mutual_info	8	data/selected_features/olive_oil_9class/m
19	olive_oil_9class	random_forest	8	data/selected_features/olive_oil_9class/rar

Consistencia de columnas en datasets reducidos

5 filas completas en CSV; se muestra una vista compacta de 5 filas.

	dataset	all_columns_exist	same_order	no_extra_columns
0	breast_cancer_wisconsin	True	True	True
1	customer_churn	True	True	True
2	madelon	True	True	True
3	olive_oil_3class	True	True	True
4	olive_oil_9class	True	True	True

Out[17]:

	dataset	all_columns_exist	same_order	no_extra_columns
0	breast_cancer_wisconsin	True	True	True
1	customer_churn	True	True	True
2	madelon	True	True	True
3	olive_oil_3class	True	True	True
4	olive_oil_9class	True	True	True

Decisión. Fase 6 debe partir de `fs_phase6_input_recommendations.csv`: cuatro métodos principales por dataset para una primera comparación, manteniendo todos los artefactos auxiliares disponibles sin mezclarlos con la parrilla principal.

5.15 Comparación narrativa y visual

****Pregunta.**** ¿Qué métodos parecen más útiles por dataset antes de modelar?

****Criterio metodológico.**** La utilidad se lee como equilibrio entre coste, estabilidad, redundancia y evidencia nula, no como rendimiento predictivo final. El rendimiento se decide en Fase 6.

```
In [18]: mostrar_tabla_compacta(
dataset_method_reading,
"Lectura de métodos principales por dataset",
columnas=["dataset", "method", "k", "mean_jaccard", "mean_selected_corr"],
max_filas=25,
formato={"mean_jaccard": numero, "mean_selected_corr": numero},
)
mostrar_figura("results/figures/05_feature_selection/summary/fs_method_profi
for dataset in dataset_summary["dataset"]:
ruta = f"results/figures/05_feature_selection/method_feature_heatmaps/{c
mostrar_figura(ruta, f"Coincidencia método-variable en {dataset}")
mostrar_figura("results/figures/05_feature_selection/visual_review_sheet/fs_
```


Lectura de métodos principales por dataset

20 filas completas en CSV; se muestra una vista compacta de 20 filas.


	dataset	method	k	mean_jaccard	mean_selected_corr	le
0	breast_cancer_wisconsin	f_classif	10	1.000	0.696	€ se
1	breast_cancer_wisconsin	mrmr_approx	10	1.000	0.372	€ se
2	breast_cancer_wisconsin	mutual_info	10	1.000	0.700	€ se
3	breast_cancer_wisconsin	random_forest	10	0.852	0.681	€ se
4	customer_churn	f_classif	10	1.000	0.096	€ se
5	customer_churn	mrmr_approx	10	0.756	0.075	sen sel alterr equiva
6	customer_churn	mutual_info	10	0.742	0.096	sen sel alterr equiva
7	customer_churn	random_forest	10	1.000	0.089	€ se
8	madelon	f_classif	10	1.000	0.244	€ se
9	madelon	mrmr_approx	10	0.111	0.017	sen sel alterr equiva
10	madelon	mutual_info	10	0.127	0.053	sen sel alterr equiva
11	madelon	random_forest	10	0.681	0.306	sen sel alterr equiva

	dataset	method	k	mean_jaccard	mean_selected_corr	l
12	olive_oil_3class	f_classif	8	1.000	0.493	€
13	olive_oil_3class	mrmr_approx	8	1.000	0.218	Se
14	olive_oil_3class	mutual_info	8	1.000	0.457	€
15	olive_oil_3class	random_forest	8	1.000	0.448	Se
16	olive_oil_9class	f_classif	8	1.000	0.461	€
17	olive_oil_9class	mrmr_approx	8	0.926	0.332	Se
18	olive_oil_9class	mutual_info	8	1.000	0.564	€
19	olive_oil_9class	random_forest	8	0.926	0.461	Se


Perfil global de métodos: coste, estabilidad y redundancia




Coincidencia método-variable en breast_cancer_wisconsin




Coincidencia método-variable en customer_churn



Coincidencia método-variable en madelon



Coincidencia método-variable en olive_oil_3class



Coincidencia método-variable en olive_oil_9class





Lámina de revisión visual de candidatas para memoria

Lámina de revisión visual - Fase 5



Lectura prudente. `f_classif` y `mutual_info` son referencias fuertes por coste y señal marginal; `mrmr_approx` aporta control de redundancia con menor estabilidad; `random_forest` añade una lectura embedded útil, pero dependiente de modelo; `variance` queda como baseline no supervisada y no debe interpretarse como evidencia de relación con el target.

5.16 Cierre, checklist y handoff

****Pregunta.**** ¿La fase queda lista para modelado sin perder cautelas?

****Criterio metodológico.**** El cierre no elige modelos. Entrega subconjuntos, riesgos y una parrilla compacta para que Fase 6 evalúe rendimiento sin contaminar validation/test.

```
In [19]: mostrar_tabla_compacta(artefactos["fs_phase5_final_checklist.csv"], "Checklist")
mostrar_tabla_compacta(artefactos["fs_phase5_handoff_to_phase6.csv"], "Handoff")
mostrar_tabla_compacta(artefactos["fs_phase5_open_issues.csv"], "Incidencias")
```

Checklist final de Fase 5

15 filas completas en CSV; se muestra una vista compacta de 15 filas.

	criterio	cumple	evidencia
0	splits cargados correctamente	True	fs_input_load_check.csv
1	selección ajustada solo con train	True	fs_experiment_log.csv
2	métodos registrados	True	fs_method_registry.csv
3	k definidos por dataset	True	fs_k_values_by_dataset.csv
4	muestreo documentado	True	fs_sampling_plan.csv
5	rankings y subconjuntos guardados	True	fs_all_rankings.csv
6	tiempos guardados	True	fs_all_execution_times.csv
7	estabilidad analizada	True	fs_jaccard_stability.csv
8	permutaciones ejecutadas	True	fs_permutation_summary.csv
9	redundancia medida	True	fs_redundancy_vs_full.csv
10	cruce con EDA generado	True	fs_selection_vs_eda_evidence.csv
11	datasets reducidos creados	True	fs_reduced_datasets_log.csv
12	figuras auditadas	True	fs_visual_audit.csv
13	informe trazable generado	True	fase5_feature_selection_report.md
14	handoff a Fase 6 creado	True	fs_phase5_handoff_to_phase6.csv

Handoff resumido a Fase 6

5 filas completas en CSV; se muestra una vista compacta de 5 filas.

	dataset	recomendacion_fase6	arte
0	breast_cancer_wisconsin	usar como entrada los directorios principal_pa...	data/selected_features/breast_cancer_wisco
1	customer_churn	usar como entrada los directorios principal_pa...	data/selected_features/customer_cl
2	madelon	usar como entrada los directorios principal_pa...	data/selected_features/mad
3	olive_oil_3class	usar como entrada los directorios principal_pa...	data/selected_features/olive_oil_3c
4	olive_oil_9class	usar como entrada los directorios principal_pa...	data/selected_features/olive_oil_9c

Incidencias y cautelas abiertas

3 filas completas en CSV; se muestra una vista compacta de 3 filas.

	dataset	issue	impact
0	customer_churn	categoricas codificadas con one-hot fit solo e...	Fase 6 debe consumir columnas seleccionadas ya... do
1	GLOBAL	artefactos auxiliares separados de entradas pr...	fs_phase6_input_recommendations.csv distingue ... do
2	olive_oil_3class olive_oil_9class	formulaciones no intercambiables	no promediar ni reutilizar rankings entre targets do

Out[19]:

	dataset	issue	impact	
0	customer_churn	categoricas codificadas con one-hot fit solo e...	Fase 6 debe consumir columnas seleccionadas ya...	c
1	GLOBAL	artefactos auxiliares separados de entradas pr...	fs_phase6_input_recommendations.csv distingue ...	c
2	olive_oil_3class olive_oil_9class	formulaciones no intercambiables	no promediar ni reutilizar rankings entre targets	c

Implicación final. La Fase 5 queda como baseline clásica trazable. Fase 6 debe evaluar si la estabilidad y la reducción dimensional observadas se traducen en rendimiento robusto, manteniendo separadas las dos formulaciones de Olive Oil y tratando `customer_churn` con su cautela de codificación train-only.